01 背景及目标

项目背景

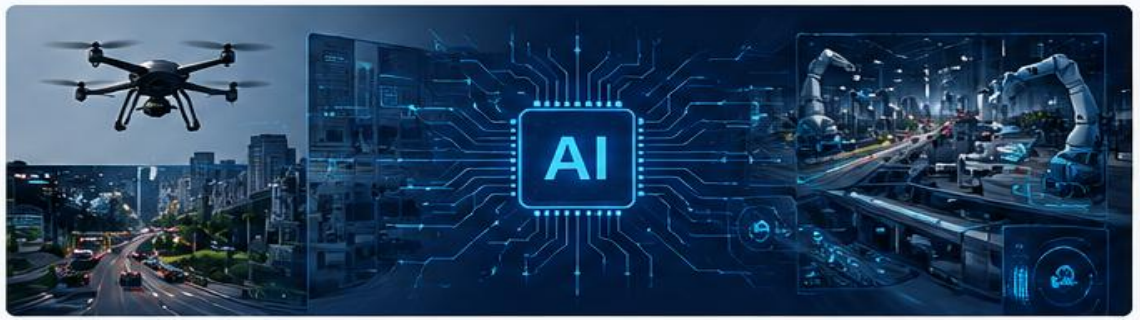
随着无人机探测、智慧交通、工业检测等领域的发展，
对高分辨率、高帧率视频的实时采集与智能分析需求日益增长。
传统方案在多路超高清视频处理时面临以下挑战：

数据吞吐量大
多路4K@200FPS带来巨大的数据带宽压力

CPU负载高
传统CPU处理难以满足实时性要求

多路同步困难
多路视频同步采集与时间对齐难度大

实时检测受限
高分辨率下目标检测精度与速度难以兼顾



项目目标

01 三路4K高速视频同步接入
实现 2×GMAX3412 + 1×GMAX0505 摄像头同步采集，
支持 3×4K@200FPS 实时输入

02 GPU实时目标检测
基于 RTX5090 + TensorRT，实现高性能目标检测与跟踪，
满足实时处理需求

03 ROI区域高速智能分析
针对 640×512 ROI 区域进行精细化分析，
推理速度达到 400FPS+

04 实时显示与数据录制
基于 ImGui 实时显示检测结果，并支持原始视频与
检测结果同步录制

05 系统性能验证与稳定运行
验证系统端到端吞吐率、延迟及稳定性，
确保长时间运行无丢帧、无卡顿

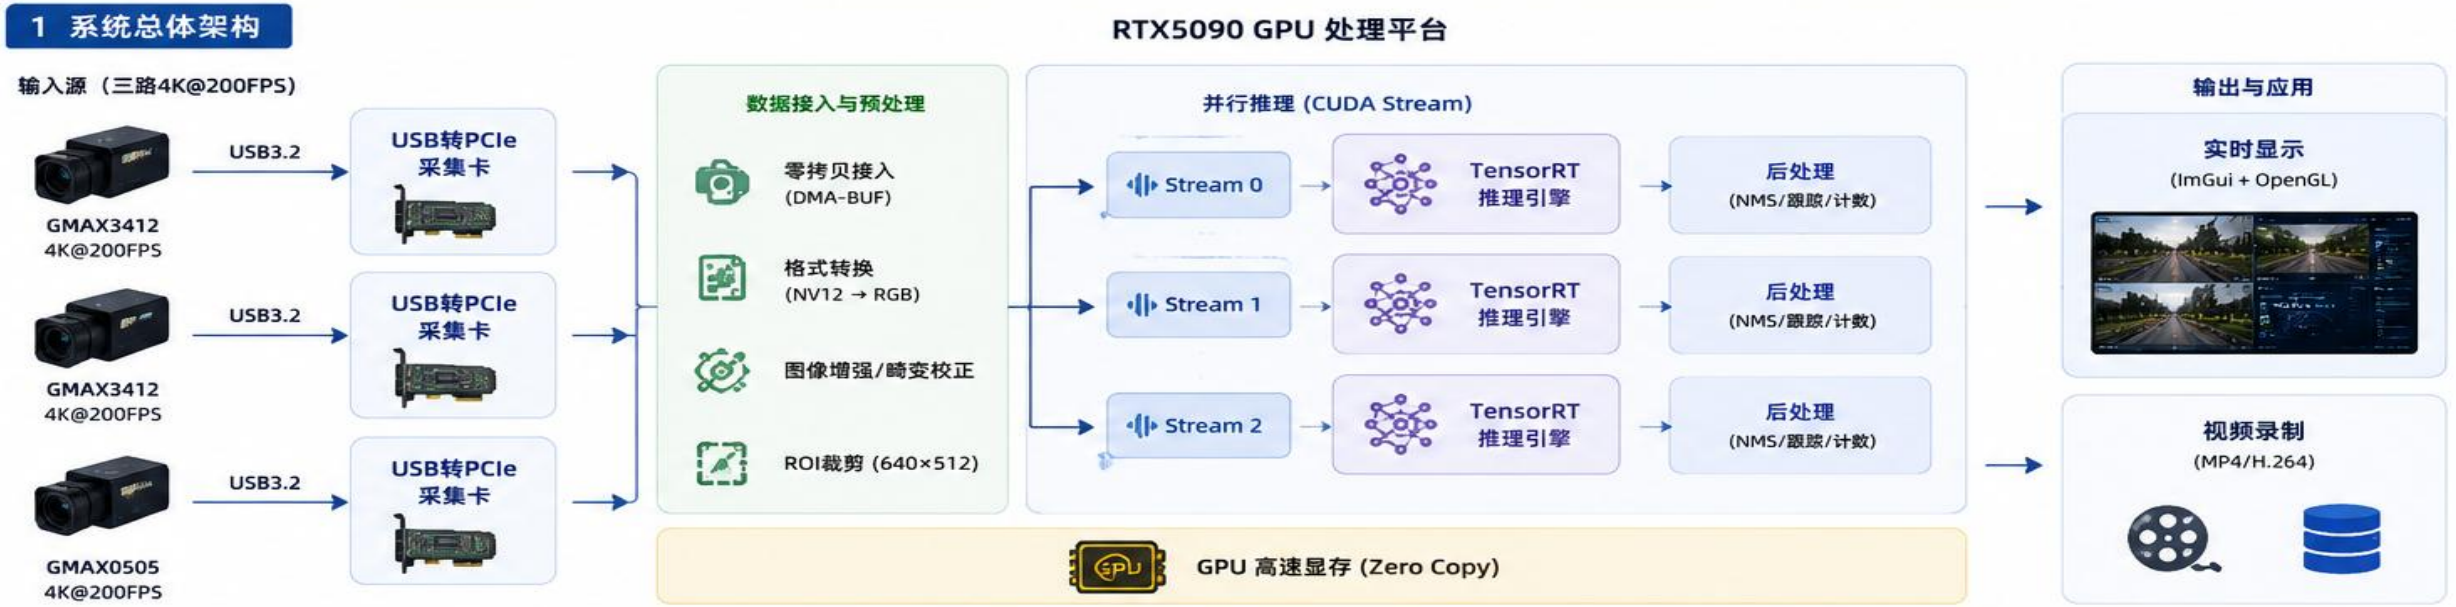
关键性能指标

输入路数	摄像头型号	输入分辨率	输入帧率	ROI尺寸	ROI检测速度	显示方式	录制能力
3路	2×GMAX3412 + 1×GMAX0505	4K (3840×2160)	200 FPS	640×512	≥400 FPS	ImGui	实时保存 (MP4)

02 方案说明

基于 RTX5090 GPU 的三路 4K 高速视频实时处理方案，实现采集、推理、显示与存储的高性能并行流水线。

1 系统总体架构



2 关键技术亮点

零拷贝数据通路
采用 DMA-BUF + CUDA External Memory，避免频繁的 CPU-GPU 数据拷贝，降低延迟，提升带宽利用率。

多线程 + 多 Stream 并行
每路视频独立线程采集，绑定独立 CUDA Stream，实现采集、推理、后处理的并行流水线。

TensorRT 高性能推理
FP16/INT8 精度优化，充分利用 Tensor Core，大幅提升 YOLOv5 推理性能。

高效显示与录制
采用 PBO 加速显示，NVENC 硬件编码，保证实时显示与高帧率录制同步进行。

3 数据处理流程



4 并行流水线示意 (三路并行)



5 技术栈

- **采集**：V4L2 / libuvc / FFmpeg
- **计算**：CUDA / TensorRT / cuDNN
- **显示**：ImGui / OpenGL
- **存储**：NVENC / MP4

YOLOv5-SAHI-UI 多路实时目标检测系统整体框架图

输入采集/硬解码 → GPU前处理 → TensorRT推理 → 后处理/NMS → GUI显示/多路拼接 → 录制与性能监控

应用层 (App Layer)

AppGUI（ImGui + GLFW + OpenGL）主线程

- 性能监控面板（FPS/延迟/CPU/GPU）
- 多路视频显示与拼接（横向/纵向/自适应）



- 通道独立配置（检测模式/阈值/SAHI参数等）
- 录制控制（独立录制/时长选择）

PipelineManager（启动/停止/配置管理）

多路Pipeline层（最多3路） Multi-Pipeline Layer

Pipeline[0]（独立线程）	Pipeline[1]（独立线程）	Pipeline[2]（独立线程）
输入源获取 (InputSource)	输入源获取 (InputSource)	输入源获取 (InputSource)
硬解码/采集 (Decoder)	硬解码/采集 (Decoder)	硬解码/采集 (Decoder)
GPU前处理 (Preprocess)	GPU前处理 (Preprocess)	GPU前处理 (Preprocess)
TensorRT推理 (Inference)	TensorRT推理 (Inference)	TensorRT推理 (Inference)
后处理/NMS (Postprocess)	后处理/NMS (Postprocess)	后处理/NMS (Postprocess)
显示/录制 (Display/Rec)	显示/录制 (Display/Rec)	显示/录制 (Display/Rec)
视频/摄像头/UVC • FFmpeg+NVDEC • V4L2 (mmap/DMABUF) • libuvc	视频/摄像头/UVC • FFmpeg+NVDEC • V4L2 (mmap/DMABUF) • libuvc	视频/摄像头/UVC • FFmpeg+NVDEC • V4L2 (mmap/DMABUF) • libuvc
NV12/YUYV/BGR GRAY/10/12bit 等多种格式	NV12/YUYV/BGR GRAY/10/12bit 等多种格式	NV12/YUYV/BGR GRAY/10/12bit 等多种格式
CUDA融合前处理 颜色转换/Resize Letterbox/Normalize HWC→CHW	CUDA融合前处理 颜色转换/Resize Letterbox/Normalize HWC→CHW	CUDA融合前处理 颜色转换/Resize Letterbox/Normalize HWC→CHW
YOLOv5 TensorRT Engine	YOLOv5 TensorRT Engine	YOLOv5 TensorRT Engine
CUDA NMS 结果解析 坐标映射	CUDA NMS 结果解析 坐标映射	CUDA NMS 结果解析 坐标映射
GPU显示 ImGui Overlay 独立录制MP4	GPU显示 ImGui Overlay 独立录制MP4	GPU显示 ImGui Overlay 独立录制MP4

... 最多3路

核心模块/引擎层 (Core Modules)

输入与解码模块

- FFmpeg HW Decoder (NVDEC)
- V4L2 Capture (mmap/pinned/ /DMABUF)
- libuvc Capture
- 多种像素格式支持

RingBuffer (4-slot)

- GPU内存预分配
- 避免动态分配
- 降低退还抖动

CUDA 融合前处理

- 色彩空间转换
- Resize / Letterbox
- Normalize
- HWC → CHW
- 写入TensorRT输入

TensorRT 引擎

- 加载 .trt / .engine
- 输入: 1×3×640×640
- 输出: 25200×85
- YOLOv5 (COCO 80类)

CUDA 后处理 / NMS

- 置信度过滤
- CUDA并行NMS
- 坐标映射到原图
- 结果输出出

GPU 显示模块

- GPU缩放到显示尺寸 (默认960×540)
- ImGui Overlay绘制
- CUDA-OpenGL互操作 低拷贝显示

录制模块

- 原始分辨率录制
- MP4 (H.264)
- 每路独立录制
- 可配置时长

基础依赖层 (Baseline)

硬件平台

NVIDIA GPU
(支持CUDA/显存)
建议：RTX 20/30/40系列

CUDA & TensorRT

CUDA Toolkit
TensorRT

多媒体库

FFmpeg (libavcodec)
NVDEC
OpenGL

系统接口

V4L2
DMA-BUF
Epoll
POSIX Threads

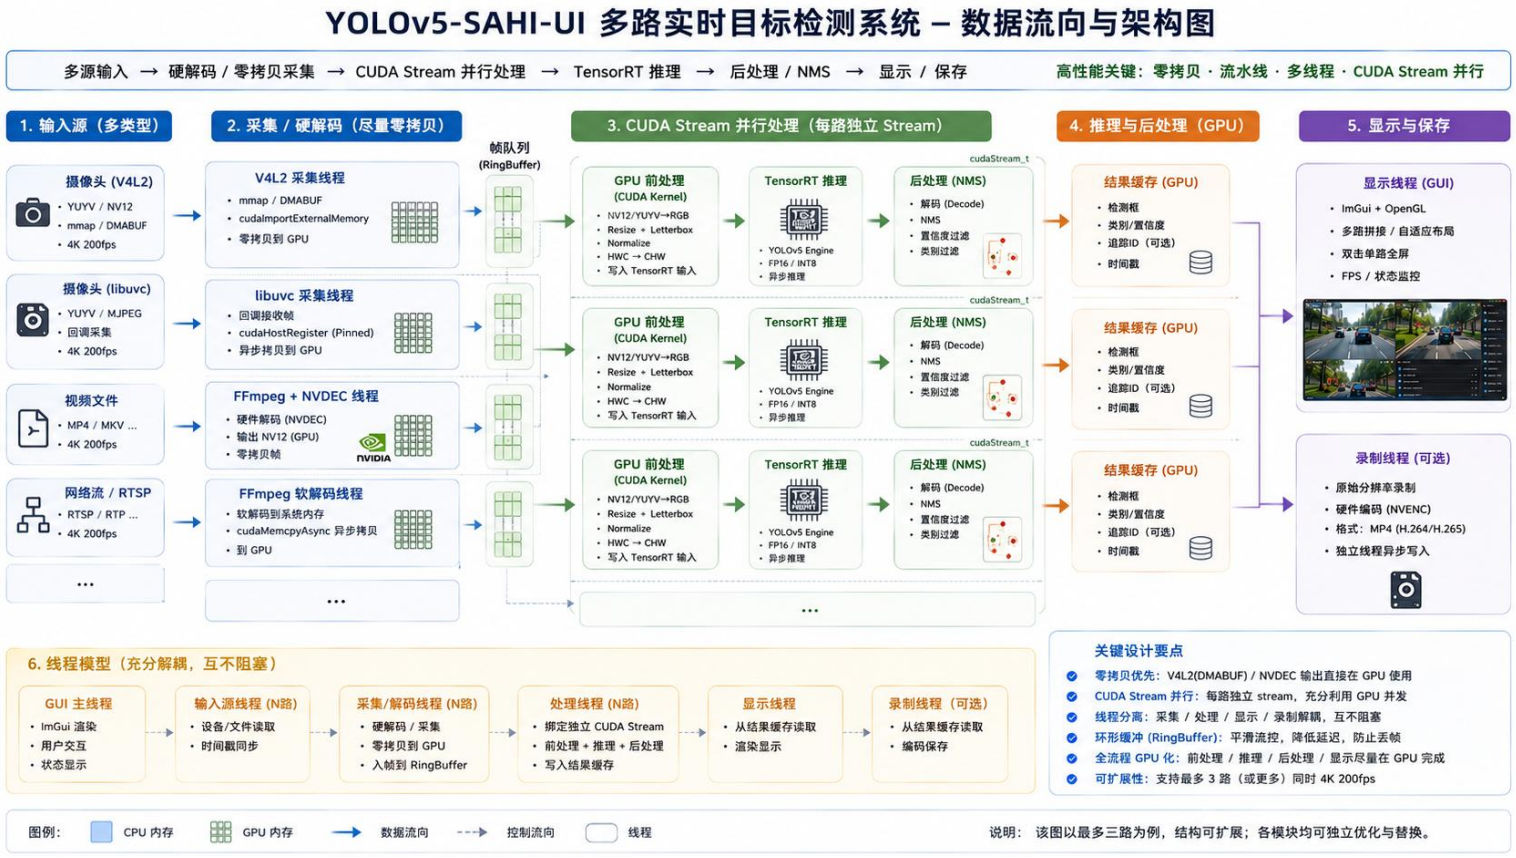
第三方库

GLFW
ImGui
libuvc

开发工具

C++17
CMake
Nsight Systems
Nsight Compute

多路并发处理



资源	设计方式	作用
Pipeline 线程	每路一个 worker thread	多路输入互不阻塞
输入采集线程	FFmpeg/V4L2/UVC 内部独立队列	采集和推理解耦
TensorRT Engine	可全局加载，也可每路独立引擎	支持不同通道不同模型
TensorRT ExecutionContext	每路独立	TensorRT context 不能被多路并发写入
CUDA Stream	每路 decode/preproc/infer/postproc 四个 stream	分阶段异步调度
RingBuffer	每路 4 个 slot	避免正在处理的帧被覆盖
GPU 显存	每路独立 input/output/display buffer	防止跨路数据竞争
GUI Result	mutex 保护 PipelineResult	主线程安全读取最新结果
录制器	每路独立	单路开始/停止录制不影响其它路

代码仓库：https://gitee.com/jack922922/gmax3412-yolov5-ui.git